

2) Problem Tanımı & Motivasyon

Alzheimer hastalığı erken dönemde tespit edilmediğinde tedavi süreci zorlaşıyor ve hastanın yaşam kalitesi düşüyor. Doktorlar MRI görüntülerini inceleyerek teşhis koyuyor ancak bu işlem zaman alıyor ve gözden kaçma ihtimali bulunuyor. Projemizde amaç, MRI görüntülerini kullanarak **otomatik bir derin öğrenme modeli geliştirmek**, hastalık belirtilerini sınıflandırmak ve tanı süresini kısaltmak.

Görev Türü:

- Sınıflandırma (Binary Classification: Alzheimer / Kontrol)

Hedef Değişkenler:

- **Normal (CN / Control):** Modelin sağlıklı bireyleri temsil ettiği sınıf.
- **MCI (Mild Cognitive Impairment / Hafif Bilişsel Bozukluk):** Alzheimer'in erken uyarı aşamasındaki bireyleri temsil eder.
- **AD (Alzheimer's Disease / Alzheimer Hastalığı):** Hastalığın klinik olarak belirginleşmiş hâlini temsil eden sınıf.

Başarı Kriterleri:

- **ROC-AUC:** Modelin Alzheimer, MCI ve Normal sınıflarını doğru ayırt etme kabiliyeti.
- **Sensitivity (Duyarlılık / Recall):** Hastalığı gerçekten olanları doğru bulma oranı (örneğin AD veya MCI sınıfında kaç kişinin doğru tespit edildiği).
- **Specificity (Özgüllük):** Sağlıklı bireyleri doğru tespit etme oranı (Normal sınıfının doğru tanımlanması).
- **F1-Score:** Precision ve Recall'ün dengeli ortalaması; özellikle sınıflar dengesizse önemlidir.

Modelin başarısı, **ROC-AUC ≥ 0.80 , sensitivity $\geq 80\%$, specificity $\geq 80\%$ ve F1-score ≥ 0.80** olarak değerlendirilecektir.

Bu projede hedeflenen performans metriği ROC AUC olup, modelin Alzheimer ve sağlıklı sınıflarını en az %85 doğrulukla ayırt edebilmesi hedeflenmiştir. Bu eşik, literatürde tıbbi görüntü sınıflandırma modelleri için kabul edilebilir ayırm gücüne karşılık gelmektedir."

3) Proje Yönetimi

Zaman Çizelgesi

- 1. Hafta:** Veri setlerinin seçimi, proje amacının netleştirilmesi, görev dağılımı yapılması
- 2. Hafta:** MRI ve ses verilerinin incelenmesi, eksik veri kontrolü, normalizasyon ve temel ön işleme işlemleri
- 3–4. Hafta:** 2D/3D CNN, Transfer Learning ve Transformer tabanlı modellerin tasarılanması, ilk eğitimlerin başlatılması
- 5–6. Hafta:** Hiperparametre optimizasyonu, öğrenme oranı–batch size ayarlamaları, model performansının iyileştirilmesi
- 7. Hafta:** Modellerin doğruluk, hassasiyet, F1-score ve loss analizlerinin yapılması, karşılaştırma tablolarının oluşturulması
- 8. Hafta:** Sonuçların raporlanması, grafikler ve görsellerin hazırlanması, sunumun tamamlanması

Roller ve Sorumluluklar

Üye 1 — Hilal Esra Akça

Sorumluluklar:

- 2D CNN için eğitim pipeline'sının kurulması, temel modelin geliştirilmesi
- 2D görüntüler için gerekli preprocessing adımlarının uygulanması
- Vision Transformer modelinin patch embedding, attention mekanizması ve eğitim sürecinin yönetilmesi
- Her iki model için hiperparametre optimizasyonu
- Eğitim ve validasyon eğrilerinin üretilmesi, loss/accuracy analizleri
- 2D CNN ve ViT modellerinin performans karşılaştırma tablolarının hazırlanması

Üye 2 — Zeynep Emeç

Sorumluluklar:

- ResNet-50 tabanlı transfer learning modelinin uygulanması ve eğitimi
- Ağ derinliği, frozen/unfrozen layer ayarları, augmentation stratejilerinin belirlenmesi
- Swin Transformer için shifted window attention yapısının uygulanması ve modelin optimize edilmesi
- Transformer modelleri için attention map analizi (ör. self-attention heatmap)
- İki mimarinin ROC-AUC, F1-score, sensitivity ve specificity skorlarının değerlendirilmesi
- Modeller arası karşılaştırma tablolarının hazırlanması

Üye 3 — Yaren Bal

Sorumluluklar:

- DenseNet-121 ile derin özellik çıkarımı ve sınıflandırma modelinin eğitimi
- MobileNet-V2 gibi hafif CNN mimarileri ile hız–performans karşılaştırması yapılması
- Sınıf dengesizliği için class-weighting, focal loss ve data augmentation stratejilerinin uygulanması
- Eğitim sürecinde hiperparametre ayarlarının (learning rate, batch size, dropout) optimize edilmesi
- DenseNet-121 ve MobileNet-V2 performans karşılaştırmalarının ve sonuç tablolarının hazırlanması

Üye 4 — Hilal Boz

Sorumluluklar:

- EfficientNet-B0 mimarisinin eğitimi, scaling parametrelerinin ve regularization stratejilerinin optimize edilmesi
- ShuffleNetV2 gibi hafif CNN mimarilerinin uygulanması ve mobil/hesaplama açısından verimli modellerin değerlendirilmesi
- ROC-AUC, precision–recall, F1-score, sensitivity ve specificity gibi metriklerin hesaplanması ve raporlanması
- Tüm modeller için değerlendirme metriklerinin standartlaştırılması ve karşılaştırma tablolarının oluşturulması
- Grad-CAM tabanlı açıklanabilirlik analizlerinin hazırlanması ve “Model Değerlendirme / Sonuçlar / Görselleştirme” bölümlerinin yazılması

Çıktılar

- Eğitilmiş modeller ve ağırlık dosyaları
- Jupyter Notebook kodları (her üye için ayrı, base model ve farklı mimariler)
- Proje raporu (PDF formatında, şablonla uygun)
- Sunum slaytları

Link: <https://github.com/zeynepemec/alzheimer-mri-classification>

4. İLGİLİ ÇALIŞMALAR (MİNİ LİTERATÜR TARAMASI)

Seçilen Temel Çalışmalar:

- Mekala & Aggarwal, 2020: MRI görüntüleriyile Alzheimer tespiti için derin öğrenme kullanılmıştır. Model olarak 2D CNN tercih edilmiş, accuracy ve ROC-AUC metrikleri raporlanmıştır.
- Korolev et al., 2017: Alzheimer sınıflandırmasında residual ve plain 2D CNN modelleri kullanılmıştır. Veri seti 150 hasta, accuracy %85.
- Cheng et al., 2019: 3D-CNN tabanlı Alzheimer sınıflandırması gerçekleştirilmiştir. Veri seti hacimsel MRI görüntülerini içermekte, ROC-AUC ve F1-score ile değerlendirilmiştir.

Literatür Karşılaştırması:

Önceki çalışmaların çoğu MRI görüntülerinde **2D slice tabanlı CNN** modelleri kullanmış, hasta düzeyinde veri ayırmayı yapılmadığı için **data leakage riski** oluşmuştur. Ayrıca sınıf dengesizliği ve erken tespit için kritik olan MCI sınıfı çoğunlukla göz ardı edilmiştir. Modelin klinik olarak yorumlanabilirliği ise sınırlı kalmıştır.

Boşluk ve Proje Yeniliği:

Bu proje, önceki çalışmalarдан farklı olarak:

1. Hasta düzeyinde veri ayırmayı yaparak **data leakage** sorununu engellemektedir.
2. Farklı derin öğrenme mimarileri (CNN tabanlı transfer learning modelleri ve Transformer tabanlı modeller) karşılaştırılarak Alzheimer sınıflandırmasında hem performans hem de hesaplama maliyeti açısından kapsamlı bir analiz sunmaktadır.
3. Sınıf dengesizliği için **class-weighting ve focal loss** stratejileri uygulanmaktadır.
4. MCI sınıfı pozitif risk grubu olarak dahil edilerek **erken tespit** odaklı bir sınıflandırma problemi tasarlanmıştır.
5. **Grad-CAM** tabanlı açıklanabilirlik yöntemleri ile modelin karar mekanizması görselleştirilmiştir.
6. Performans, ROC-AUC, PR-AUC, sensitivity, specificity ve F1-score gibi **klinik bağlamda anlamlı metriklerle** değerlendirilmiştir.

Bu yönleriyle proje, aynı veri setini kullanan klasik CNN yaklaşımılarına göre hem erken tespit odaklı, hem daha güvenilir ve hem de klinik olarak yorumlanabilir bir yapı sunmaktadır.

5. VERİ AÇIKLAMASI VE YÖNETİMİ

Veri Kümesi:

- Kaggle Alzheimer MRI Dataset: 0–255 aralığında piksel yoğunlukları içeren 2D ön işlenmiş MRI görüntülerini. Alzheimer, MCI ve Normal sınıflarını içeren çok sınıflı bir veri kümesidir.

Şema ve Değişkenler:

- Görüntü değişkenleri: 2D MRI slice'larındaki piksel yoğunlukları
- Klinik değişkenler: Bu projede doğrudan kullanılmamış, sadece sınıf etiketleri üzerinden çalışılmıştır.

Boyut ve Sınıf Dengesi:

- Kaggle: Toplam görüntü sayısı sınıflar arasında tam dengeli değildir; bu nedenle class weighting ve data augmentation stratejileri kullanılmıştır.

Etik, Gizlilik ve Önyargı:

- Hassas Alanlar: MRI görüntülerini sağlık verisi olduğundan hassastır.
- Kimlik Gizleme: Veriler anonimleştirilmiştir, ancak teorik olarak yüz/kimlik çıkarımı mümkün değildir.
- Adalet ve Önyargı: Yaş, cinsiyet veya etnik dağılım dengesiz olabilir; tek merkez/veri cihazı genellenebilirliği sınırlayabilir.
- Kişisel Veriler ve Onay: Veri setinin lisans ve kullanım koşullarına uyulmuştur.
- Sınırımlar: Demografik çeşitlilik kısıtlı olabilir, ön işleme klinik bilgileri azaltabilir, etiketler insan yorumuna bağlı olduğundan hata içerebilir.

6. YÖNTEMLER VE MİMARİ

Bu proje Alzheimer hastalığının erken tespiti için MRI görüntülerini kullanarak derin öğrenme modelleri geliştirmeyi hedeflemektedir. Projede her grup üyesi en az iki farklı derin öğrenme mimarisinde çalışacak ve modellerin performansı ROC-AUC, sensitivity, specificity ve F1-score metrikleri ile değerlendirilecektir. Modellerin tüm mimari detayları, hiper parametreleri ve uygulanacak veri setleri aşağıda özetlenmiştir.

Üye 1 — Hilal Esra Akça

- 2D CNN modelinin geliştirilmesi ve eğitim süreci
- ViT mimarisinin uygulanması, patch embedding ve attention analizi
- Hiperparametre optimizasyonu ve eğitim döngüsü yönetimi
- Eğitim–validasyon grafiklerinin oluşturulması

Üye 2 — Zeynep Emeç

- ResNet-50 modeli ile transfer learning uygulamaları
- Swin Transformer mimarisinin eğitilmesi (shifted window attention)
- Model karşılaştırma tablolarının oluşturulması
- Transformer attention görselleştirmeleri

Üye 3 — Yaren Bal

- DenseNet-121 modeli ile derin özellik çıkarımı ve çok sınıfı Alzheimer sınıflandırması
- MobileNet-V2 gibi daha hafif bir CNN mimarisi ile performans–hesaplama maliyeti karşılaştırması yapılması
- Sınıf dengesizliği için class-weighting ve focal loss stratejilerinin denenmesi
- Data augmentation (döndürme, yatay çevirme, parlaklık/kontrast değişimi) ile genellemeye performansının artırılması

Üye 4 — Hilal Boz

- EfficientNet-B0 mimarisinin eğitilmesi ve Kaggle Alzheimer MRI verisi üzerinde optimize edilmesi
- ShuffleNetV2 gibi hafif CNN mimarilerinin eğitilmesi ve EfficientNet ile kıyaslanması
- ROC-AUC, F1, sensitivity, specificity gibi metriklerin tüm modeller için hesaplanması ve karşılaştırılması
- Grad-CAM ve benzeri açıklanabilirlik yöntemleri ile model çıktılarının görselleştirilmesi
- Son raporlama, sonuç ve görselleştirme bölümlerinin hazırlanması

Veri Ön İşleme ve Eğitim Süreci:

- Kaggle Alzheimer MRI veri seti kullanılacaktır.
- Tüm modeller 2D MRI slice'ları üzerinde çalışılacak; farklı CNN ve Transformer tabanlı mimariler (2D CNN, ResNet, DenseNet, EfficientNet, MobileNetV2, ShuffleNetV2, ViT, Swin Transformer) karşılaştırılacaktır.
- Transformers modelleri, MRI görüntülerindeki global ve lokal ilişkileri öğrenmek için kullanılacaktır.
- Veri setleri hasta düzeyinde ayrılacak, train-validation-test setleri oluşturulacak, sınıf dengesizliği için class-weighting ve focal loss stratejileri uygulanacaktır.
- Eğitim aşamasında hiper parametre optimizasyonu grid search veya Bayesian optimization ile yapılacaktır.

Model Değerlendirme:

- Modellerin başarısı ROC-AUC ≥ 0.80 , sensitivity $\geq 80\%$, specificity $\geq 80\%$ ve F1-score ≥ 0.80 olarak değerlendirilecektir.
- Grad-CAM ve benzeri açıklanabilirlik yöntemleri ile modelin karar mekanizması görselleştirilecektir.

7.DENEY TASARIMI

7.1. Train–Test Ayrımı

- Veri seti, sınıflar dengeli olacak şekilde %70 eğitim – %15 validasyon – %15 test oranına bölündü.
- Stratified split kullanılarak her alt grupta aynı sınıf oranı korundu.
- 2D dilimler kullanıldığında, aynı hastaya ait dilimler birden fazla bölüme düşmemesi için hasta-bazlı ayırım yapıldı. 3D MRI verisi için volumetrik blok bazlı hasta ayımı uygulandı; böylece data leakage önlandı.

7.2. Hedef Değer (Target) Belirleme

- Hedef değer ikili sınıflandırma (Demented / Non-Demented) ve çoklu sınıflandırma (Normal, MCI, AD) olarak tanımlanı.
- Kategorik etiketler one-hot encoding veya label encoding ile modele uygun hale getirildi.
- Pozitif risk grubu olarak MCI sınıfı özel olarak ele alındı; AD+MCI / CN ikili sınıflandırması da yapılabilir.

7.3. Validasyon Yöntemi

- Ana validasyon yöntemi hold-out validation (%15) olarak belirlendi.
- Eğitim sırasında Early Stopping ile aşırı öğrenme önlendi (val_loss izlenerek, patience=10).
- Ek olarak, küçük alt örnek üzerinde 5-katlı K-Fold Cross Validation test edildi.

7.4.Hiperparametre Optimizasyonu

- Grid Search: Öğrenme oranı (1e-4, 1e-5), batch size (16, 32), dropout (0.3, 0.5)
- Random Search: Optimizasyon algoritması (Adam, RMSprop), katman/filtre sayısı, data augmentation şiddeti
- Random Search, geniş aralıkları hızlı taradığı için ana yöntem olarak tercih edildi. Model bazlı parametre farklılıklarını (3D CNN, ViT) ayrı tablolarla raporlanacak.

7.5.Değerlendirme Kriterleri ve Final Sonuçlar

- Accuracy, F1-score, ROC-AUC, sensitivity, specificity gibi metrikler kullanılacak.
- Örnek:
 - Eğitim doğruluğu: %96
 - Validasyon doğruluğu: %92
 - Test doğruluğu: %90
 - F1-score: 0.88
 - ROC-AUC: 0.91
 - Sensitivity: 85%

- Specificity: 87%
- Kaydedilen en iyi model: Learning rate = 1e-4, Batch size = 32, Dropout = 0.4
- Sonuç: Model, overfitting göstermeden test setinde yüksek genelleme performansı sağladı. Öğrenme ve metric eğrileri appendix bölümüne eklenecek.

8.KULLANILAN ARAÇLAR VE FRAMEWORKLER

Derin Öğrenme Kütüphaneleri:

- **PyTorch** kullanılacak.
- Model geliştirme, eğitim ve değerlendirme bu kütüphane üzerinden yürütülecek.

Python Kütüphaneleri ve Sürüm Bilgileri:

Python \geq 3.9

- **NumPy, Pandas, Scikit-learn:** Veri işleme, analiz ve sınıflandırma öncesi hazırlık.
- **Matplotlib, Seaborn:** Performans grafiklerinin ve görselleştirmelerin çizimi.
- **Torchvision, MONAI (opsiyonel):** Medikal görüntü işleme ve önceden eğitilmiş modeller için.
- Seed: Grup içinde tüm modeller aynı random seed ile başlatılacak, sonuçların tekrarlanabilirliği için.

Donanım Gereksinimleri:

- GPU: NVIDIA RTX 3060 veya üstü önerilir.
- CPU: En az 6 çekirdekli işlemci.
- RAM: \geq 16 GB

Geliştirilen Kodlar ve Versiyon Kontrolü:

- Tüm kodlar **GitHub** üzerinde paylaşılacak.

Link: <https://github.com/zeynepemec/alzheimer-mri-classification>

ÜYE 1 — HİLAL ESRA AKÇA

1) 2D CNN (Custom)

Accuracy: %84

Yorum:

Temel bir 2D CNN modeli olmasına rağmen slice bazlı MRI görüntülerinde makul bir başarı elde etmiştir. Lokal özellikleri öğrenmede iyi performans göstermiş; ancak Alzheimer, MCI ve Normal sınıfları arasındaki ince farkları yakalamada sınırlı kalmıştır. Özellikle MCI sınıfında karışmalar gözlenmiştir. Transfer learning modellere göre daha düşük ancak stabil bir performans üretmiştir.

2) Vision Transformer (ViT)

Accuracy: %90

Yorum:

ViT, global ilişkileri öğrenme kapasitesi sayesinde Alzheimer ve MCI ayırımında belirgin biçimde daha yüksek performans göstermiştir. Özellikle beyin yapısının geneline yayılmış atrofi paternlerini iyi yakaladığı için 2D CNN'den daha üstündür. Overfitting riskine rağmen doğru regularization kullanımı ile stabil bir model elde edilmiştir.

ÜYE 2 — ZEYNEP EMEÇ

1) ResNet-50

Accuracy: %88

Yorum:

ResNet-50, transfer learning avantajı ile güçlü bir temel performans göstermiştir. Alzheimer sınıflandırmasında yaygın olarak kullanılan bir model olup, özellikle Normal-AD ayrimında yüksek doğruluk sağlamıştır. MCI sınıfını ayırma başarısı Transformer modellerinden düşük olsa da CNN tabanlı modeller arasında oldukça başarılıdır.

2) Swin Transformer

Accuracy: %92

Yorum:

Swin Transformer, hem lokal patch ilişkilerini hem de global beyin bölgeleri arasındaki bağlantıları yakalaması sayesinde Transformer modelleri arasında en iyi performansı vermiştir. Shifted window mekanizması MRI gibi yapısal verilerde güçlü sonuçlar üretmiştir. Özellikle MCI tespitinde belirgin iyileşme sağlamıştır.

ÜYE 3 — YAREN BAL

1) DenseNet-121

Accuracy: %89

Yorum:

DenseNet, yoğun bağlantılı yapısı sayesinde derin özellikleri etkili şekilde öğrenmiştir. Alzheimer'ın erken evrelerinde görülen daha ince yapısal değişiklikleri yakalama konusunda

klasik CNN ve ResNet modellerine göre daha başarılıdır. Özellikle MCI sınıfındaki karışıkların azaldığı gözlenmiştir. Parametre sayısı görece yüksek olsa da, transfer learning

sayesinde stabil ve güçlü bir performans elde edilmiştir.

2) MobileNet-V2

Accuracy: %86

Yorum:

MobileNet-V2, hafif ve mobil cihazlara uygun bir mimari olmasına rağmen Alzheimer sınıflandırmasında tatmin edici bir doğruluk sağlamıştır. DenseNet-121'e kıyasla biraz daha

düşük accuracy üretse de parametre sayısı ve hesaplama maliyeti ciddi şekilde azdır. Bu nedenle gerçek zamanlı veya kaynak kısıtlı ortamlarda tercih edilebilecek pratik bir alternatif olarak değerlendirilmiştir

ÜYE 4 — HİLAL BOZ

1) EfficientNet-B0

Accuracy: %87

Yorum:

EfficientNet, parametre—hesaplama dengesi sayesinde hızlı ve etkili bir modeldir.

Daha hafif olmasına rağmen ResNet seviyesine yakın performans göstermiştir.

Özellikle

Normal—AD ayrimında güçlü sonuçlar üretmiş, ancak MCI sınıfını ayırmada

Transformer

tabanlı modellere göre bir miktar zorlanmıştır. Yine de sınırlı veri ve donanım

koşullarında

yüksek verimlilik sunan bir mimari olarak öne çıkmaktadır.

2) ShuffleNetV2

Accuracy: %85

Yorum:

ShuffleNetV2, mobil ve gömülü sistemler için tasarlanmış son derece hafif bir CNN yapısıdır.

Bu projede hesaplama maliyeti en düşük modellerden biri olmasına rağmen Alzheimer sınıflandırma

performansı kabul edilebilir düzeydedir. Özellikle inference süresinin kısa olması sebebiyle,

yüksek doğruluk gerektirmeyen ancak hızlı karar vermenin önemli olduğu senaryolarda potansiyel

bir aday model olarak değerlendirilmiştir.

9. KAYNAKLAR

Veri Setleri

[1] P. Jain, *Preprocessed Alzheimer's Disease MRI Dataset*, Kaggle, 2021. Available: <https://www.kaggle.com/datasets/prasukjain07/preprocessed-alzheimers-disease-mri-dataset>

İlgili Makaleler

[3] S. Mekala and P. Aggarwal, "Alzheimer Disease Detection Using Deep Learning," 2020.

[4] S. Korolev et al., "Residual and Plain CNNs for Alzheimer Classification," 2017.

[5] D. Cheng et al., "Classification of Alzheimer's MRI Using 3D-CNN," 2019.

Kullanılan Kütüphaneler & Frameworkler

[6] PyTorch, Available: <https://pytorch.org/>

[7] NumPy, Pandas, Scikit-learn, Matplotlib, Seaborn

[8] Torchvision, MONAI